


# A8-SeriesDeTiempo

Oskar Arturo Gamboa Reyes

2024-11-12

## Cargar Datos

```
data <- data.frame(  
  year = rep(1:4, each = 4),  
  trimester = rep(1:4, times = 4),  
  ventas = c(4.8, 4.1, 6.0, 6.5, 5.8, 5.2, 6.8, 7.4, 6.0, 5.6, 7.5, 7.8, 6.3,  
5.9, 8.0, 8.4)  
)  
  
# Convertir a serie de tiempo  
ventas_ts <- ts(data$ventas, start = c(1, 1), frequency = 4)  
  
# Graficar la serie de tiempo  
plot(ventas_ts, main = "Ventas por Trimestre", xlab = "Tiempo", ylab =  
"Ventas (miles)", col = "red", lwd = 2)
```



## Estacionaridad

### Prueba de Dickey-Fuller

```
library(tseries)

## Warning: package 'tseries' was built under R version 4.4.2

## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo

adf_test = adf.test(ventas_ts)
print(adf_test)


##
## Augmented Dickey-Fuller Test
##
## data:  ventas_ts
## Dickey-Fuller = -2.7111, Lag order = 2, p-value = 0.3015
## alternative hypothesis: stationary
```

Como podemos observar el p-value obtenido es mayor a 0.05 por lo que podemos aceptar la hipótesis nula por lo que es probable que sea una serie de tiempo no estacionaria ya que esta demuestra una tendencia clara.

### Autocorrelación

```
acf(ventas_ts, main = "Funcion de Autocorrelacion", col = "red")
```

## Funcion de Autocorrelacion




La barra del Lag 1 está significativamente por arriba de la linea azul lo que respresenta una alta autocorrelación positiva, esto significa que las ventas de un trimestre estan relacionadas con el trimestre anterior.

La alta autocorrelación indica que esta serie tiene patrones estacionales, además al tener autocorrelación podemos confirmar que esta serie de tiempo es una serie no estacionaria.

### Multiplicativa o Aditiva


```
ventas_decomp_add <- decompose(ventas_ts, type = "additive")  
plot(ventas_decomp_add)
```

## Decomposition of additive time series



```
ventas_decomp_mult <- decompose(ventas_ts, type = "multiplicative")  
plot(ventas_decomp_mult)
```

## Decomposition of multiplicative time series



La serie muestra una tendencia creciente y una estacionalidad clara, lo cual sugiere que ambos modelos pueden representar adecuadamente los datos. Sin embargo a simple vista puedo estimar que es un modelo aditivo ya que vemos que no hay un cambio durante la tendencia de la serie.

## Indices estacionales y serie desestacionalizada

### Indices

```
descom_aditiva <- decompose(ventas_ts, type = "additive")
indices_estacionales_aditivo <- descom_aditiva$seasonal
```

```
indices_estacionales_aditivo
```

```
##           Qtr1           Qtr2           Qtr3           Qtr4
## 1 -0.4395833 -1.0687500  0.5895833  0.9187500
## 2 -0.4395833 -1.0687500  0.5895833  0.9187500
## 3 -0.4395833 -1.0687500  0.5895833  0.9187500
## 4 -0.4395833 -1.0687500  0.5895833  0.9187500
```

### Serie desestacionalizada

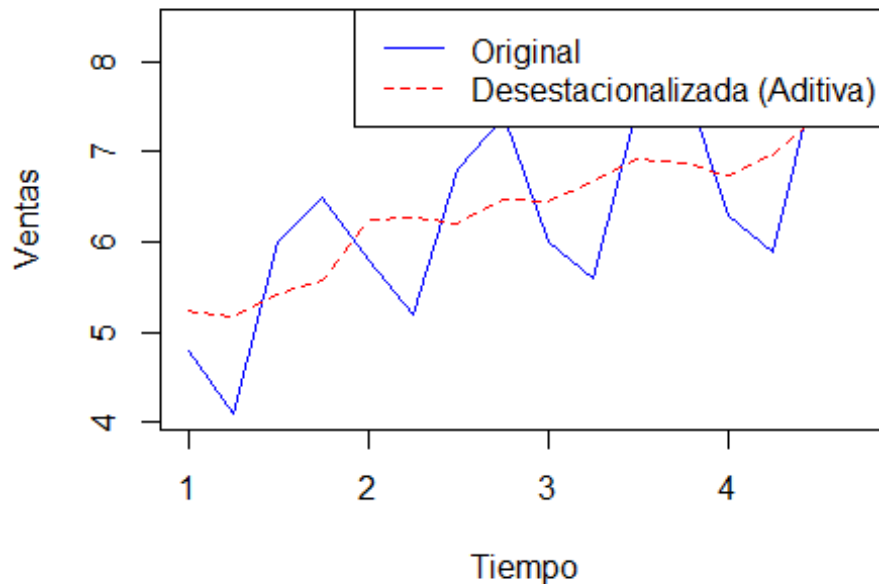
```
ventas_desestacionalizada_aditiva <- ventas_ts - indices_estacionales_aditivo
```

```
plot(ventas_ts, main = "Serie Temporal Original y Desestacionalizada", col =
"blue", ylab = "Ventas", xlab = "Tiempo")
```

```
lines(ventas_desestacionalizada_aditiva, col = "red", lty = 2)
```

```
legend("topright", legend = c("Original", "Desestacionalizada (Aditiva)"),
      col = c("blue", "red"), lty = 1:2)
```

## Serie Temporal Original y Desestacionalizada



# Análisis de

tendencia

### Modelo Lineal

```
tiempo <- 1:length(ventas_desestacionalizada_aditiva)
modelo_lineal <- lm(ventas_desestacionalizada_aditiva ~ tiempo)
```

```
summary(modelo_lineal)
```

```
##
## Call:
## lm(formula = ventas_desestacionalizada_aditiva ~ tiempo)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.2992 -0.1486 -0.0037  0.1005  0.3698
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   5.13917    0.10172   50.52  < 2e-16 ***
## tiempo        0.14613    0.01052   13.89  1.4e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.194 on 14 degrees of freedom
## Multiple R-squared:  0.9324, Adjusted R-squared:  0.9275
## F-statistic: 193 on 1 and 14 DF, p-value: 1.399e-09
```

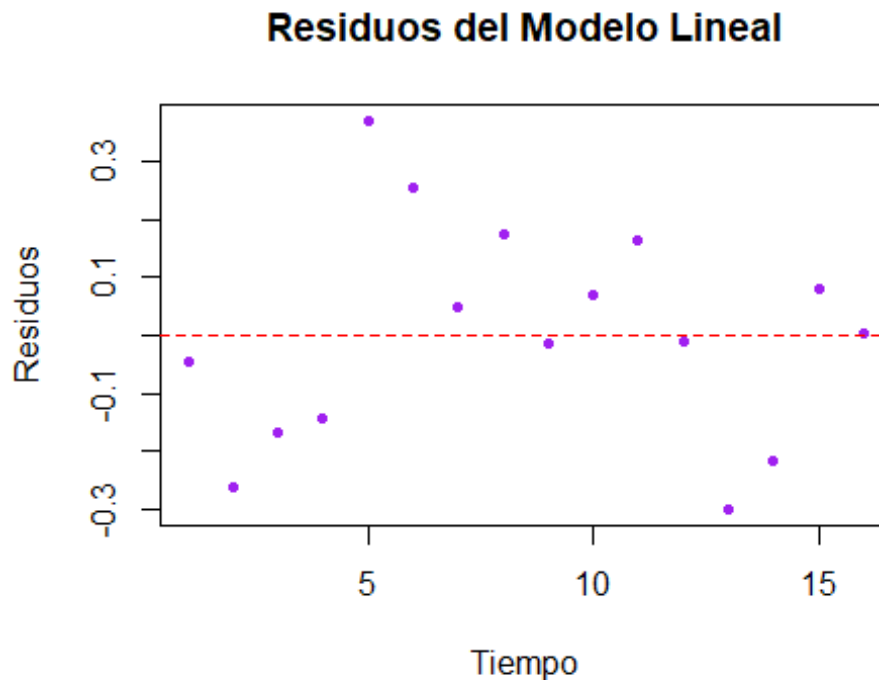
**Global** La prueba F tiene un valor bastante bajo ( $1.399e-09$ ) lo que sugiere que el tiempo tiene un impacto significativo en las ventas desestacionalizadas, además los valores de R-squared son bastante altos (0.93 y 0.92) por lo que el modelo explica casi toda la variabilidad de las ventas. Estos resultados sugieren que es significativo globalmente.

**Individual** Los dos coeficientes muestran valores p extremadamente bajos, en especial el de tiempo lo que indica una tendencia significativa de crecimiento en las ventas desestacionalizadas a medida que avanza el tiempo.

## Residuos


### Gráfica

```
plot(modelo_lineal$residuals, main = "Residuos del Modelo Lineal", ylab =  
"Residuos", xlab = "Tiempo", col = "purple", pch = 20)  
abline(h = 0, col = "red", lty = 2)
```



### Normalidad

```
# Gráfico QQ para verificar la normalidad de los residuos  
qqnorm(modelo_lineal$residuals)  
qqline(modelo_lineal$residuals, col = "blue")
```



```
# Prueba de Shapiro-Wilk
shapiro.test(modelo_lineal$residuals)

##
##  Shapiro-Wilk normality test
##
## data:  modelo_lineal$residuals
## W = 0.97816, p-value = 0.9473
```

Podemos ver que los residuos tienen una tendencia normal y muestran que están distribuidos simétricamente alrededor del cero lo que apoya la adecuación del modelo lineal a la tendencia.

## CME y EPAM

```
datos_entrenamiento <-
ventas_desestacionalizada_aditiva[1:(length(ventas_desestacionalizada_aditiva)
- 4)]
tiempo_entrenamiento <- tiempo[1:(length(tiempo) - 4)]

modelo_lineal_entrenamiento <- lm(ventas_desestacionalizadas ~ tiempo, data =
data.frame(ventas_desestacionalizadas = datos_entrenamiento, tiempo =
tiempo_entrenamiento))

tiempo_validacion <- tiempo[(length(tiempo) - 3):length(tiempo)]
```



```

predicciones_ultimo_ano <- predict(modelo_lineal_entrenamiento, newdata =
data.frame(tiempo = tiempo_validacion))

ventas_reales <-
ventas_desestacionalizada_aditiva[(length(ventas_desestacionalizada_aditiva )
- 3):length(ventas_desestacionalizada_aditiva )]

# Calcular el CME
CME <- mean((ventas_reales - predicciones_ultimo_ano)^2)

# Calcular el EPAM
EPAM <- mean(abs((ventas_reales - predicciones_ultimo_ano) / ventas_reales))
* 100

# Mostrar resultados
cat("CME:",CME, "\n")

## CME: 0.1106827

cat("EPAM:",EPAM)

## EPAM: 4.332883

data
##      year trimester ventas
## 1      1          1    4.8
## 2      1          2    4.1
## 3      1          3    6.0
## 4      1          4    6.5
## 5      2          1    5.8
## 6      2          2    5.2
## 7      2          3    6.8
## 8      2          4    7.4
## 9      3          1    6.0
## 10     3          2    5.6
## 11     3          3    7.5
## 12     3          4    7.8
## 13     4          1    6.3
## 14     4          2    5.9
## 15     4          3    8.0
## 16     4          4    8.4

```

## Predicción Siguiente Año

```

modelo_lineal <- lm(ventas_desestacionalizadas ~ tiempo, data =
data.frame(ventas_desestacionalizadas = ventas_desestacionalizada_aditiva ,
tiempo = tiempo))

```

```

tiempo_futuro <- seq(max(tiempo) + 1, max(tiempo) + 4, by = 1)
predicciones_futuro <- predict(modelo_lineal, newdata = data.frame(tiempo =
tiempo_futuro))
ventas_predichas <- predicciones_futuro + indices_estacionales_aditivo[1:4]
tiempo_total <- c(tiempo, tiempo_futuro)
ventas_total <- c(ventas_desestacionalizada_aditiva, ventas_predichas)

# Graficar los datos originales y las predicciones
plot(tiempo, data$ventas, type = "l", col = "blue", ylim =
range(c(data$ventas, ventas_predichas+2)), xlim = range(c(0,22)), xlab =
"Tiempo", ylab = "Ventas", main = "Prediccion de los siguientes 4
trimestres")
lines(tiempo_futuro, ventas_predichas, col = "red", lty = 2)
legend("topright", legend = c("Datos originales", "Prediccion"),
col = c("blue", "red"), lty = c(1, 2))

```

